

Aragon AI Assistent — FAQ Sicherheit & Datenschutz

System: Aragon Maestro | **Modell:** Qwen (via llama.cpp) | **Oberfläche:** llama-ui + eigene MCP-Server

Zielgruppe: Kunden und Endnutzer

Stand: Juni 2026

Überblick

Dieses Dokument beantwortet die häufigsten Fragen von Kunden zum verwendeten KI-Modell im Aragon-Assistenten, seinem Sicherheitsprofil und den konkreten Maßnahmen zum Schutz von Nutzerdaten und Systemintegrität. Es ist auf Ehrlichkeit, Transparenz und technische Genauigkeit ausgerichtet.

F1 — Welches KI-Modell verwendet Aragon, und warum wird es manchmal als „unsicher“ bezeichnet?

Das Modell

Aragon verwendet **Qwen**, eine Familie großer Sprachmodelle (LLMs), die von **Alibaba Cloud** entwickelt und als Open-Weight-Modelle unter permissiven Lizenzen veröffentlicht wurden[cite:16]. Die eingesetzte Variante läuft lokal über **llama.cpp**, eine weit verbreitete Open-Source-Inferenz-Engine.

Was „unsicher“ tatsächlich bedeutet

Der Begriff „unsicher“ in der KI-Sicherheitsliteratur bedeutet **nicht**, dass das System gefährlich zu bedienen ist oder dass Ihre Daten gefährdet sind. Er bezieht sich speziell auf **Schwächen bei Inhalts-Schutzmaßnahmen (Guardrails)** — das heißt, das Modell kann unter Umständen durch adversarielle Eingaben (sogenannte „Jailbreaks“) dazu gebracht werden, schädliche Texte zu erzeugen, wie Schadcode, gefährliche Anleitungen oder Betrugs-Inhalte[cite:5][cite:7].

Unabhängige Evaluierungen haben Qwen-Modelle in dieser Dimension als kritisch schwach eingestuft[cite:3]. Vergleichbare Probleme bestehen bei Modellen wie DeepSeek und in geringerem Maß bei westlichen Modellen wie GPT-4 und Llama[cite:4]. Kein kommerzielles LLM gilt heute als vollständig sicher gegenüber allen adversariellen Eingaben.

Was das in der Praxis bedeutet

Für den Aragon-Einsatz gilt:

- Alle Modelleingaben durchlaufen eine **Prompt-Sanitisierung**, bevor sie das Modell erreichen

- Alle Modellausgaben werden über **eigene MCP-Server** geleitet, die mögliche Aktionen des Modells einschränken
- Das Modell hat **keinen Internetzugang** während der Inferenz
- Der Assistent **eignet sich nicht für kritische oder hochriskante Entscheidungen** (medizinische, rechtliche oder finanzielle Beratung mit Regulierungsanforderungen)

F2 — Ist Qwen ein chinesisches Modell? Besteht das Risiko, dass meine Daten nach China übertragen werden?

Modellherkunft vs. Datenziel

Qwen wird von Alibaba Cloud, einem chinesischen Unternehmen, entwickelt und unterliegt in seiner Cloud-Form chinesischer Rechtsprechung[cite:1]. Der Aragon-Einsatz verwendet jedoch die **Open-Weight-Version** von Qwen — die Modellgewichte werden einmalig heruntergeladen und laufen vollständig auf lokaler Infrastruktur[cite:36][cite:45].

Das bedeutet:

- Keine Anfragen, Prompts oder Antworten werden an Alibaba-Cloud-Server übermittelt
- Während der Inferenz werden keine API-Aufrufe an externe Dienste getätigt
- Alibaba hat keine technische Möglichkeit, auf Gesprächsdaten zuzugreifen

DSGVO-Implikationen

Da die gesamte Verarbeitung lokal erfolgt, erfüllt der Einsatz **DSGVO-Artikel 25** (Datenschutz durch Technikgestaltung) und vermeidet die Pflichten aus **Artikel 44** zu Drittlandübermittlungen[cite:36]. Der Betreiber handelt als **Nutzer eines Open-Weight-Modells**, nicht als Cloud-Service-Abonnent — eine rechtlich eigenständige und risikoärmere Rolle im Sinne des EU-KI-Gesetzes.

F3 — Ist das System zu 100 % sicher?

Die ehrliche Antwort

Kein KI-System ist zu 100 % sicher — und jeder Anbieter, der das behauptet, sollte kritisch hinterfragt werden. Der Aragon-Assistent bietet starke, nachweisbare Schutzmaßnahmen, trägt aber wie alle LLM-basierten Systeme inhärente Einschränkungen, die Kunden kennen sollten.

Was garantiert wird:

- Nutzerdaten verlassen die lokale Infrastruktur nicht[cite:36][cite:45]
- Die Modellgewichte enthalten keinen ausführbaren Code oder versteckte Exfiltrations-Mechanismen — das GGUF-Format (verwendet von llama.cpp) ist nicht ausführbares Gewichts-Datenformat[cite:40]

- Der Zugriff auf Werkzeuge (Dateisystem, APIs, Shell-Befehle) wird ausschließlich über abgegrenzte MCP-Server kontrolliert; das System exponiert keine Befehle auf Betriebssystemebene[cite:31]
- Die Integrität der Modell-Checkpoints ist über SHA-256-Hashes verifizierbar, abgeglichen mit den offiziellen Qwen-Releases auf HuggingFace[cite:34]

Was nicht garantiert werden kann:

- Faktische Richtigkeit aller Antworten — LLMs können halluzinieren oder plausibel klingende, falsche Informationen produzieren
- Vollständige Resistenz gegenüber adversariellen Prompts — ein gezielter Angreifer kann unerwartete Ausgaben provozieren[cite:43]
- Eignung für kritische Entscheidungen — der Assistent ist für den allgemeinen Gebrauch konzipiert, nicht für regulierte oder sicherheitskritische Bereiche

F4 — Wie können Kunden diese Sicherheitsaussagen überprüfen?

Technische Nachweise sind auf Anfrage für jede Aussage verfügbar:

Aussage	Überprüfungsmethode
Keine ausgehende Datenübertragung	Netzwerkverkehrsaufzeichnung (Wireshark/tcpdump) während einer Live-Inferenzsitzung, ohne externe Verbindungen
Saubere Modellgewichte	SHA-256-Hash der GGUF-Dateien verglichen mit offiziellen Qwen-Checksums auf HuggingFace[cite:34]
Nicht ausführbare Gewichte	Quellcode-Review von llama.cpp, der bestätigt, dass GGUF nur interpretiert wird, ohne Shell-Ausführungspfad aus den Gewichten[cite:40]
Abgegrenzter MCP-Werkzeugzugriff	Review der MCP-Server-Konfiguration mit expliziten Berechtigungsgrenzen[cite:33]
Keine OS-Shell-Exposition	Bestätigung, dass llama.cpp nicht mit dem Flag <code>--tools all</code> betrieben wird, das <code>exec_shell_command</code> und Datei-I/O-Werkzeuge freigeben würde[cite:31]
Aktive Eingabe-Sanitisierung	Code-Review der Prompt-Vorverarbeitungs-Pipeline vor der Modell-Invokation

F5 — Welche Risiken bleiben bestehen und wie werden sie gehandhabt?

Verbleibende Risiken

Risiko	Wahrscheinlichkeit	Gegenmaßnahme
Halluzination (falsche, aber sichere Antworten)	Mittel	Menschliche Überprüfung empfohlen; der Assistent darf nicht einzige Informationsquelle sein
Prompt-Injection durch adversarielle Nutzereingaben	Niedrig-Mittel	Eingabe-Sanitierungsschicht; MCP-Server schränkt Werkzeugumfang ein[cite:33][cite:43]

Risiko	Wahrscheinlichkeit	Gegenmaßnahme
Unerwartetes agentisches Verhalten	Niedrig	Kein autonomer Internetzugang; Werkzeugaufrufe erfordern explizite MCP-Berechtigungen[cite:31]
Modellbias oder politisch gefilterte Ausgaben	Niedrig (lokales Modell)	Keine Live-Inhaltsfilterung durch Alibaba; Modellverhalten ist nach Deployment statisch
GGUF-Lieferkettenkompromittierung	Sehr niedrig	Nur offizielle Qwen-Releases werden verwendet; Checksums bei Download verifiziert[cite:34][cite:40]

Was in diesem Deployment kein Risiko darstellt

- **Daten nach China übertragen:** Nicht möglich — keine API-Aufrufe, vollständig offline Inferenz[cite:36][cite:45]
- **Echtzeit-Überwachung:** Das Modell hat keine persistente Erinnerung zwischen Sitzungen, sofern nicht explizit implementiert
- **Malware in den Gewichten:** Das GGUF-Format kann keinen beliebigen Code ausführen; llama.cpp ist das einzige Laufzeitsystem[cite:40]

Zusammenfassung für Kunden

Der Aragon-Assistent verwendet Qwen, ein Open-Weight-Modell, das vollständig auf lokaler Infrastruktur ohne externe Datenübertragung läuft. Die Bezeichnung „unsicher“ in KI-Sicherheits-Benchmarks bezieht sich auf Schwächen bei Inhalts-Guardrails, die praktisch alle aktuellen LLMs teilen — nicht auf Datensicherheits- oder Überwachungsrisiken. Die lokale Deployment-Architektur eliminiert die wesentlichen Bedenken gegenüber chinesischen Modellen. Nachprüfbare technische Belege für alle Sicherheitsaussagen sind auf Anfrage erhältlich.

Für kritische Entscheidungen immer menschliches Urteilsvermögen einsetzen. Der Assistent ist ein Werkzeug, keine Autorität.